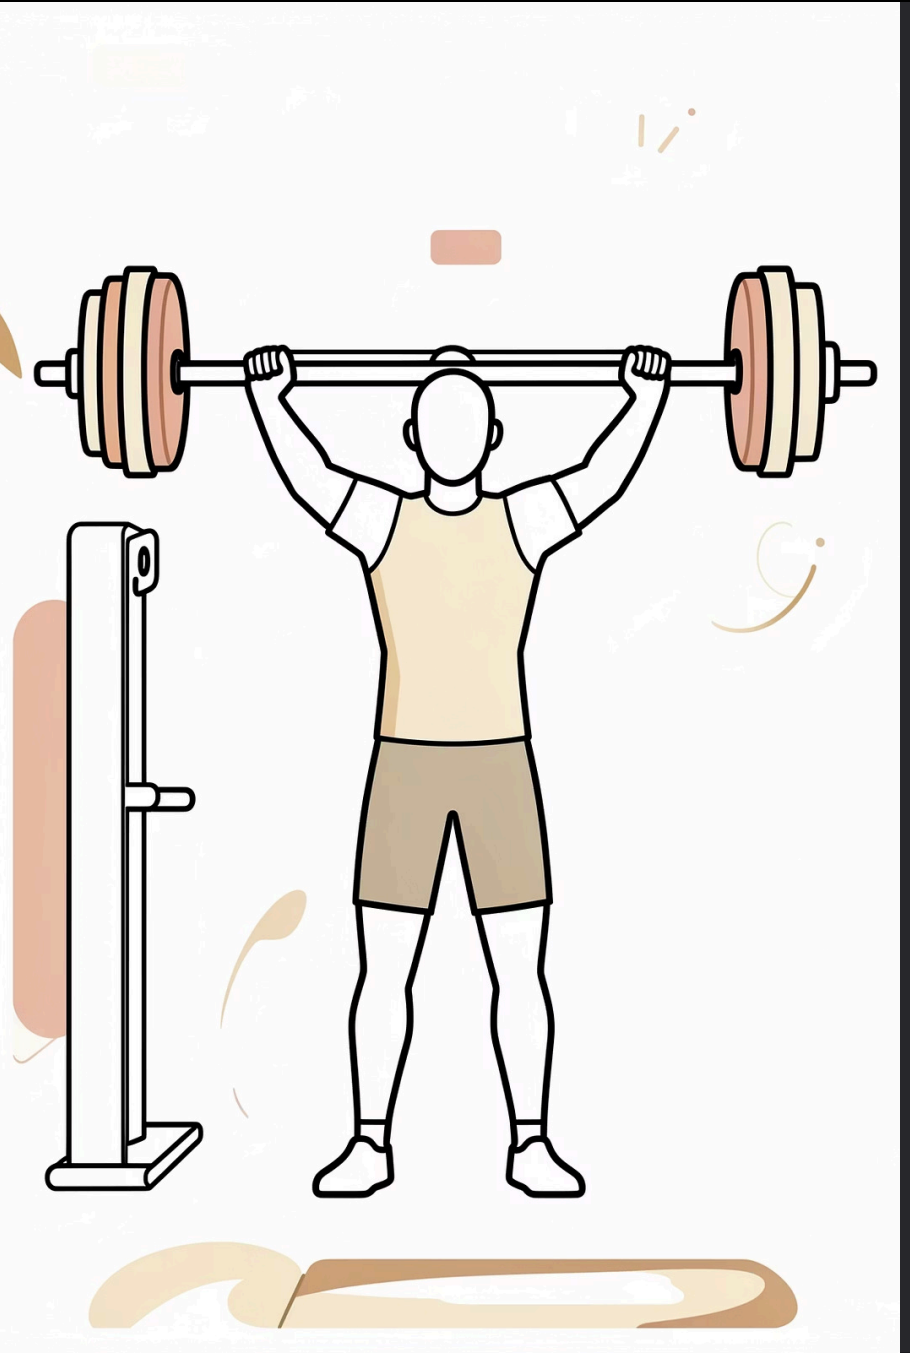

PROYECTO FINAL DE GRADO · UCASAL 2026

Evaluación Automatizada de Técnica en Ejercicios de Fitness mediante Aprendizaje Profundo y Visión por Computadora

Autor: Ignacio Villanueva | **Tutor:** Mg. Lic. Lorena Talamé

UCASAL — Facultad de Ingeniería e Informática — Ingeniería en Informática

Nota de diseño: incluir logo-ucasal.png en este slide

Made with GAMMA

MOTIVACIÓN

El Origen del Proyecto

El punto de partida fue una conversación con el Instituto de Rehabilitación de UCASAL que buscaba mejorar sus prestaciones.

Sin supervisión

Riesgo de lesión por falta de experiencia. El practicante no detecta sus propios errores de técnica.

Con supervisión humana

Mejor opción pragmática, poco escalable

La pregunta

¿Puede una cámara estándar evaluar la técnica de forma automática, objetiva y accesible?

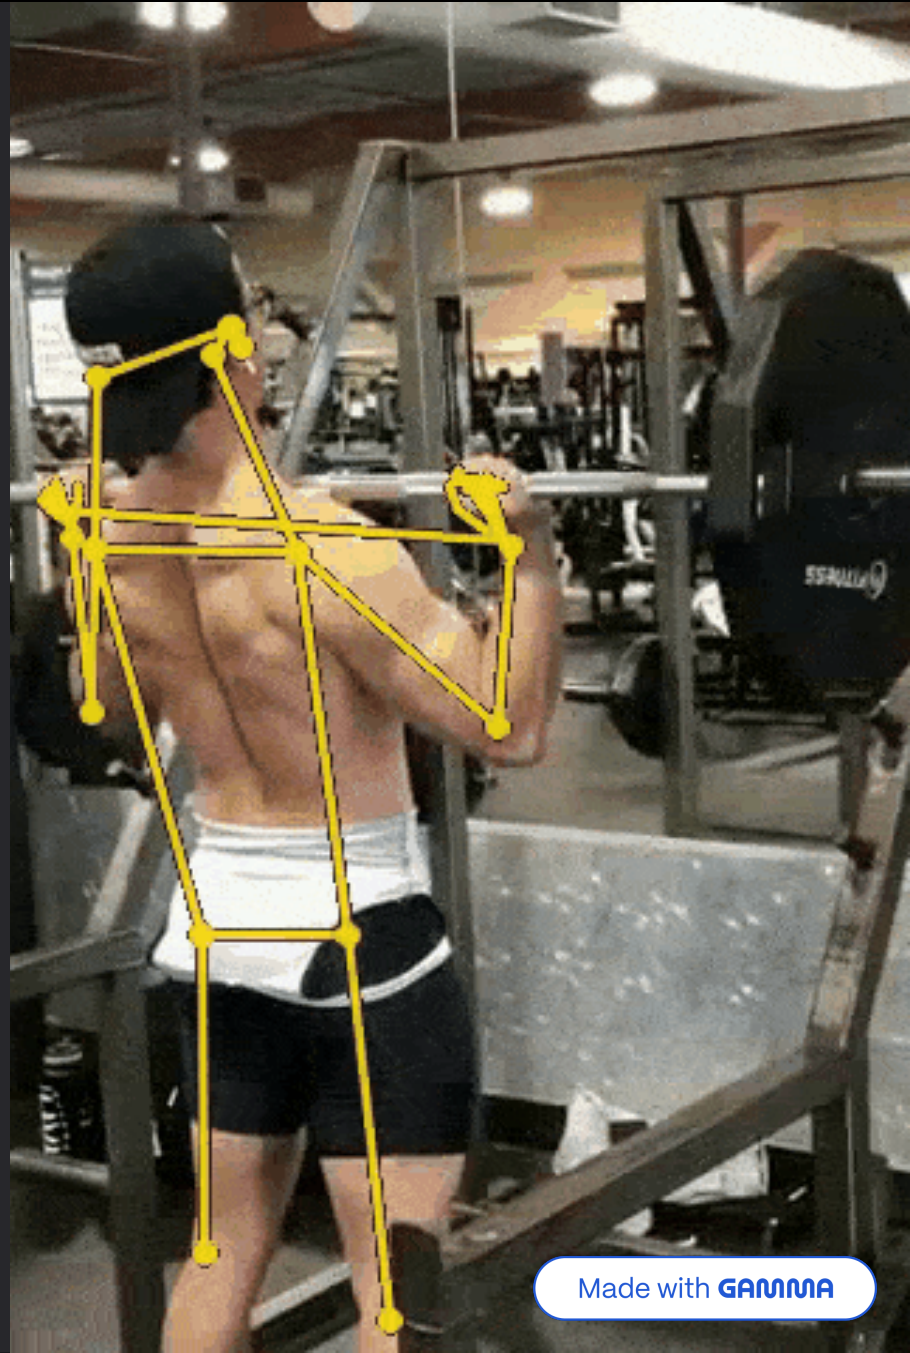

Made with GAMMA

Un poco de Contexto

Nula experiencia inicial.

Distintos campos del conocimiento.

Intercambios estudiantiles

1

UCASAL

Salta, Argentina

2

Universidad de Cádiz

España

3

POSTECH

Corea del Sur

Made with GAMMA

ESTUDIO INICIAL

Las Alternativas Existentes

El sistema desarrollado utiliza video RGB estándar y herramientas open-source, reduciendo la barrera económica que imponen las soluciones existentes en el mercado.

Sistema	Tecnología	Costo aproximado
VICON / OptiTrack	Captura de movimiento 3D con marcadores	USD $10,000–$100,000+
Physimax / Kaia Health	IA para análisis de movimiento, SaaS	USD $50–$200/mes
Tempo / Mirror	Hardware dedicado + suscripción software	USD $1,500 + $39/mes
Este proyecto	**Video RGB estándar + herramientas open-source**	**$0**

Made with GAMMA

ARQUITECTURA

La Solución: El Pipeline

El sistema analiza videos de personas realizando press de hombro y clasifica automáticamente la técnica en tres categorías. El flujo completo es reproducible y documentado.

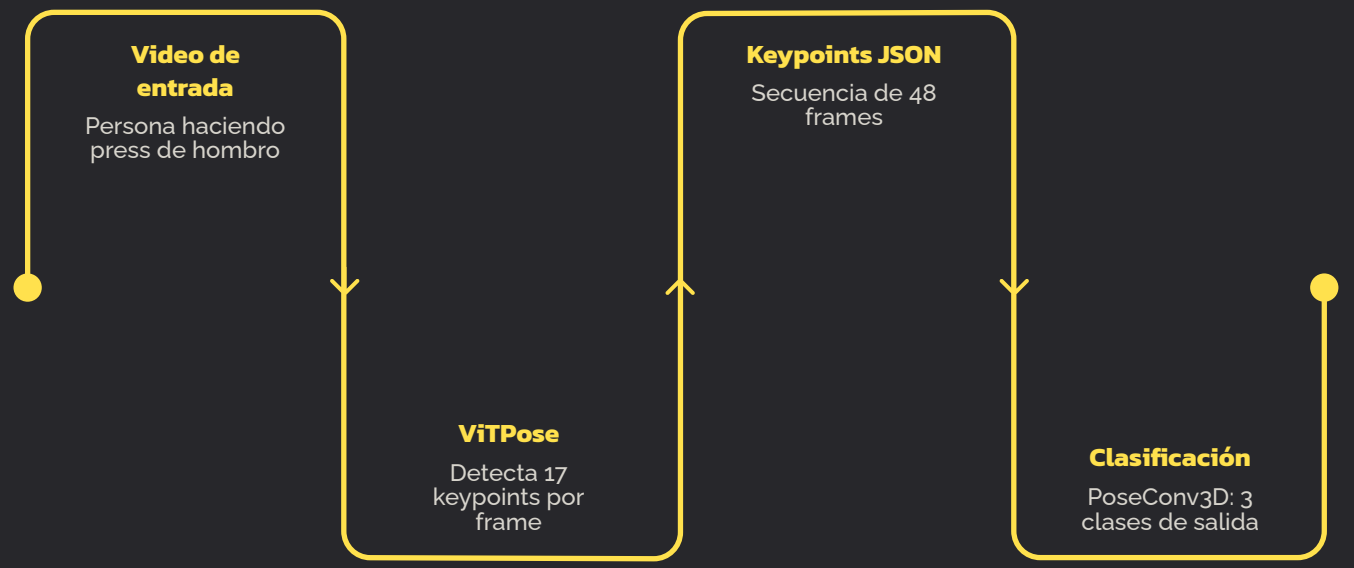

ViTPose — Estimación de Poses

Detecta 17 puntos articulares por frame usando Vision Transformers. Enfoque top-down: YOLOv8 detecta personas → ViTPose estima la pose dentro de cada bounding box.

Assets de referencia: keypoints COCO diagram.png, Dosovitskiy ViT architecture.png

PoseConv3D — Clasificación Temporal

Analiza 48 frames de heatmaps de keypoints y clasifica el movimiento completo. Backbone: ResNet3D SlowOnly, 12 millones de parámetros. Dataset: 2,135 videos etiquetados del Fitness-AQA (1,708 entrenamiento / 427 validación).

Asset de referencia: tensorflow 3DCNN.png

Made with GAMMA

¿Por qué ViTPose?

Para entender el movimiento del cuerpo humano, la forma en que el modelo "ve" las articulaciones es fundamental.

Otras herramientas (OpenPose, MediaPipe)

Modelos tradicionales como OpenPose o MediaPipe procesan la imagen en pequeñas porciones. Intentan identificar partes del cuerpo de forma local y luego ensamblarlas.

- Analizan la imagen en partes, de forma local.
- Para conectar codo con hombro, necesitan combinar mucha información por separado.

ViTPose

ViTPose, basado en Vision Transformers, adopta una perspectiva global desde el principio. Es como si pudiera ver todo el esqueleto a la vez, comprendiendo las relaciones espaciales entre las articulaciones de forma inherente.

- Ve todas las articulaciones en relación, al mismo tiempo.
- Entiende de un vistazo cómo el codo se conecta con el hombro y la muñeca.

ViTPose entiende el cuerpo como un todo, no como una suma de partes.

Made with GAMMA

CONTRIBUCIÓN TÉCNICA

El Problema del Tracking

ViTPose no tiene memoria entre frames — los IDs se reasignan. Una persona con ID "44" puede desaparecer y reaparecer como ID "51", haciendo que el modelo vea múltiples personas donde hay una sola. Este problema motivó el desarrollo de una solución original.

Algoritmo de Corrección de Tracking

Contribución técnica original del proyecto. La regla exacta: desaparición ≤3 frames + reaparición ≤25 píxeles → el ID original se mantiene. Resultado: **87% de discontinuidades corregidas**.

Detectar discontinuidad | **Verificar condiciones** | **Reasignar ID**

Made with GAMMA

LÓGICA EXPERIMENTAL

La Lógica de los Experimentos

Analizamos el rendimiento del modelo a través de tres etapas clave, cada una respondiendo a una pregunta fundamental.

¿Aprende sin conocimiento previo?

Experimento Base

NO — 51.2%, overfitting severo.

¿Ayuda el conocimiento preentrenado?

Transfer Learning

PARCIALMENTE — 70.5%, overfitting reducido.

¿El problema era el modelo o los datos?

Configuración Final

LOS DATOS — 91.6%, convergencia estable.

Made with GAMMA

RESULTADOS · EXPERIMENTOS

Evolución del Rendimiento del Modelo

El salto de 70% → 92% vino de mejores datos, no de un modelo más complejo.

51.2%

Baseline

ResNet3D desde cero. F1: 0.48. Pérdida val: ~1.5 — overfitting severo.

70.5%

Transfer Learning

Pesos de NTU60 (56,880 videos). +19.3pp sobre baseline. F1: 0.69.

91.6%

Configuración Final

Dataset reconstruido + AdamW + Pose Jittering. F1-macro: 0.91. Brecha: 2–4%.

Nota de diseño: incluir gráficos de pérdida y precisión de los tres experimentos: baseline_experimento_*.png, experimento_250522_*.png, experimento_250525_*.png

Experimento	Precisión (val)	F1-macro
Baseline (sin transfer learning)	51.2%	0.48
Transfer Learning (NTU60)	70.5%	0.69
Configuración Final	**91.6%**	**0.91**

Made with GAMMA

ANÁLISIS DE LA MEJORA

Qué cambia en la configuración final y por qué

El salto de 70% a 92% no vino de un modelo más grande. Vino de entender por qué los datos eran inconsistentes.

Cambio	Problema que resolvía
Dataset reconstruido con tracking corregido	El modelo veía 5–10 "personas" distintas donde había solo 1 en el mismo video, confundiendo los patrones de movimiento.
AdamW en lugar de SGD	SGD ajustaba todos los pesos de la red con la misma fuerza, lo que podía dificultar la convergencia; AdamW adapta la tasa de aprendizaje para cada peso, acelerando y estabilizando el entrenamiento.
Pose Jittering (σ=2px)	ViTPose tiene una imprecisión inherente al detectar coordenadas de keypoints; este "ruido" sintético en los datos de entrenamiento hizo que el modelo fuera más robusto a pequeñas variaciones.
Label smoothing (ε=0.1)	Previene que el modelo sea excesivamente confiado en sus predicciones, reduciendo el sobreajuste y mejorando la generalización a datos no vistos.

Made with GAMMA

RESULTADOS · MÉTRICAS FINALES

Resultados por Clase

El sistema fue evaluado sobre 427 videos de validación del dataset Fitness-AQA. Se compara con Parmar et al. (2022), quienes usaron clasificadores binarios separados sobre el mismo dataset (F1 codos: 0.45, F1 rodillas: 0.84). Este trabajo logra **F1 0.91 global** con un único clasificador multiclase.

Clase	Precision	Recall	F1-Score	Support
Técnica Correcta	0.94	0.92	0.93	~179
Error de Codos	0.90	0.92	0.91	~128
Error de Rodillas	0.89	0.91	0.90	~120
Macro avg	**0.91**	**0.92**	**0.91**	**427**

Nota de diseño: incluir matriz_confusion.png como visual complementario

Made with GAMMA

ANÁLISIS COMPARATIVO

Comparación Académica

Este trabajo establece un nuevo estándar al superar la efectividad de enfoques anteriores con un modelo más eficiente.

Métrica	Parmar et al. (2022)	Este Trabajo
Estrategia	2 clasificadores binarios	1 clasificador multiclase
Dataset	Fitness-AQA	Fitness-AQA (mismo)
F1 — Codos	0.45	**0.91**
F1 — Rodillas	0.84	**0.90**
F1 — Global	—	**0.91**

Un clasificador unificado supera a dos clasificadores especializados — en ambas categorías.

Made with GAMMA

RESULTADOS · MATRIZ DE CONFUSIÓN

Qué dice la matriz de confusión

There was an error generating this image

- Diagonal alta → clasificación correcta en la mayoría de los casos.
- Pocos errores cruzados entre las clases de error.
- F1 similar en las tres clases → sin sesgo hacia la clase mayoritaria.

Made with GAMMA

Conclusiones

Objetivos cumplidos

Los 4 objetivos específicos planteados al inicio del proyecto fueron alcanzados en su totalidad.

Pipeline completo y reproducible

Sistema documentado de extremo a extremo: desde la captura de video hasta la clasificación de técnica.

Contribución original

Algoritmo de corrección de tracking que corrigió el 87% de las discontinuidades de ID entre frames.

Alternativa de $0

Frente a sistemas que cuestan entre USD $10,000 y $100,000+, este proyecto opera con video estándar y herramientas open-source.

Made with GAMMA

TRABAJO FUTURO

Trabajo Futuro

El sistema establece una base sólida para futuras extensiones en múltiples direcciones de investigación y aplicación.

Más errores de técnica

Extender la clasificación a nuevas categorías de errores biomecánicos más allá de codos y rodillas.

Localización temporal

Identificar en qué frame exacto ocurre el error dentro de la secuencia de movimiento.

Más ejercicios

Generalizar el pipeline a otros movimientos compuestos como sentadilla, peso muerto y press de banca.

Integración con LLMs

Generar retroalimentación natural y personalizada a partir de los resultados de clasificación.

Validación con usuarios reales

Estudios de usabilidad con practicantes y profesionales del fitness en entornos reales.

Made with GAMMA